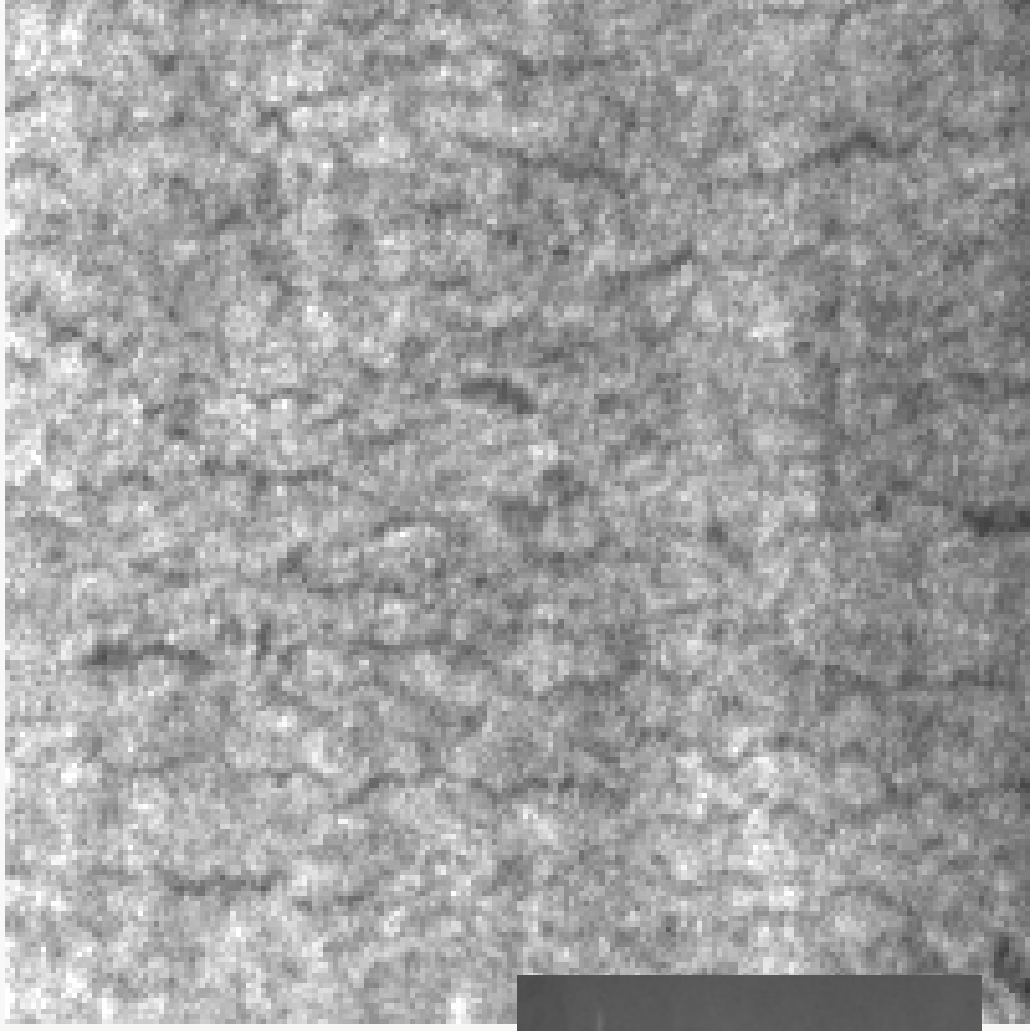
딥러닝 개인 프로젝트

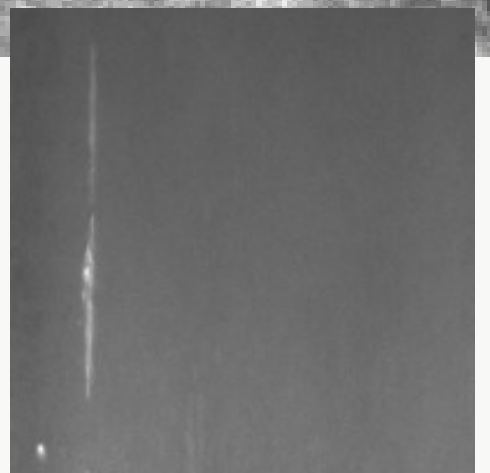
딥러닝 기반 금속 표면 불량 유형 분류 시스템

Metal Surface Defect Classification

CNN 기반 이미지 다중 분류 및
Grad-CAM 판단 근거 시각화

NEU Surface Defect Database · TensorFlow/Keras · Streamlit





작성자 : 김수현

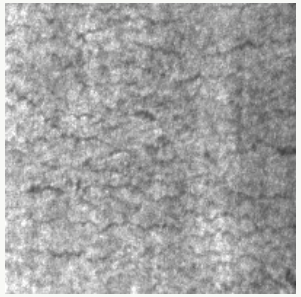
작성일 : 2026.11.05

목차

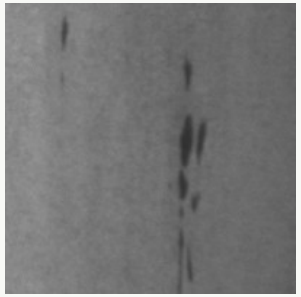
01	프로젝트 개요	배경 · 문제 정의 · 목표	03
02	프로젝트 수행 범위	개발 범위 및 환경	04–05
03	프로젝트 추진 방법	딥러닝 프로젝트 수행 프로세스	06
04	데이터 이해 및 전처리	데이터 수집 · EDA · 정규화 · 계층 분할	07–10
05	모델 개발 및 평가	CNN 학습 · 테스트 · 오류 · Grad-CAM · GAP 추가 실험	11–25
06	프로토타이핑	Streamlit 웹앱 구현 · Community Cloud 배포	26–27
07	보완 사항	현재 한계 · 향후 개선 방향	28–29
08	결론 및 회고	프로젝트 결론 · 활용 가능성 · 회고	30–31

금속 표면 결함 분류의 배경과 목적

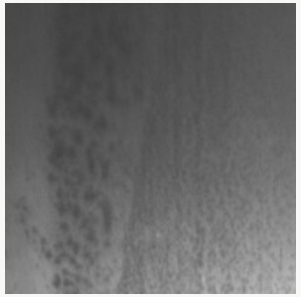
결함 이미지의 유형을 구분하고 , 분류 결과와 모델의 한계를 함께 분석



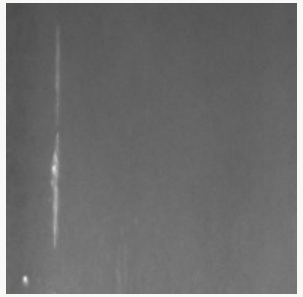
균열



개재물



표면 패임



스크래치

표면 결함마다 형태와 질감이 다르며 ,
일부 유형에는 유사한 선형 흔적이 나타난다 .

분석이 필요한 문제	프로젝트의 접근
유형 간 비슷한 형태 · 질감	CNN 의 공간적 특징 학습
평균 정확도만으로 취약점 파악 어려움	클래스별 지표 · 혼동행렬 분석
모델이 참고한 영역을 확인할 필요	Grad-CAM 기여도 시각화

목적 **6 종 결함 분류 모델을 구현하고 , 성능 · 오류 · 예측 기여 영역을 분석한다 .**

프로젝트 수행 범위 및 구현 성과

NEU-CLS 이미지 기반 결함 유형 분류 프로토타입

1,800 장

NEU-CLS 이미지

6 종

금속 표면 결함 분류

93.33%

Baseline CNN 테스트 정확도

주요 구현 범위

데이터 분석	모델 개발	결과 해석 · 비교	서비스 구현
EDA· 전처리	CNN 학습 · 평가	오분류 ·Grad-CAM	Streamlit 웹앱
클래스 분포 · 픽셀 분석 정규화 · 계층 분할	모델 저장 독립 테스트 평가	추가 경량화 비교 클래스별 오류 분석	최대 20 장 배치 분석 예측 확률 · 공개 배포

범위 제외 정상 · 불량 이진 판정 , 결함 좌표 · 면적 검출 , 생산라인 카메라 연동

데이터 · 모델 선정 및 개발 환경

입력 데이터의 일관성과 이미지의 공간적 특징을 기준으로 선정

NEU-CLS 선정

6 클래스 금속 표면 결함 라벨 제공

클래스별 300 장 균형적인 표본 구성

200×200 흑백 이미지 크기 · 채널 일관

CNN 선정

공간적 특징 추출 선 · 경계 · 질감의 형태 학습

단일 이미지 분류 시간 순서가 없는 입력

Grad-CAM 연동 last_conv 특징 맵 활용

기술 스택	프로젝트에서의 역할
Python · Jupyter	분석 · 실험 실행
TensorFlow · Keras	CNN 설계 · 학습 · 추론
NumPy · pandas	배열 처리 · 결과 정리
Matplotlib · seaborn	EDA · 학습 · 평가 시각화
scikit-learn · Pillow	데이터 분할 · 평가 · 이미지 처리
Streamlit	웹앱 인터페이스
GitHub · Cloud	소스 관리 · 웹앱 배포

실제 로컬 개발 환경 확인 : TensorFlow 2.21.0 / Keras 3.15.1. 배포 환경의 Python 은 3.11 로 조정 .

딥러닝 프로젝트 수행 프로세스

데이터 구성부터 모델 평가 · 해석 , 추가 실험과 서비스 구현까지

01

데이터 수집

NEU-CLS 1,800 장
6 종 결함 이미지

02

EDA

분포 · 대표 이미지
픽셀 밝기 분석

03

전처리 · 분할

float32 · 정규화
Train / Val / Test

04

Baseline 설계

Conv 32 · 64 · 128
Flatten · Softmax

05

학습 · 저장

최적 가중치 복원
cnn_model.keras

06

테스트 평가

독립 Test 270 장
지표 · 혼동행렬

07

오분류 분석

클래스별 오류
Scratches 사례

08

Grad-CAM

정답 · 오답 비교
예측 기여 영역

09

GAP 추가 비교

동일 Val 270 장
경량화 · 성능 절충

10

웹앱 · 배포

Streamlit 연동
공개 서비스

NEU-CLS 데이터 수집 및 구성

금속 표면 결함 유형 분류를 위한 6 클래스 이미지 데이터셋

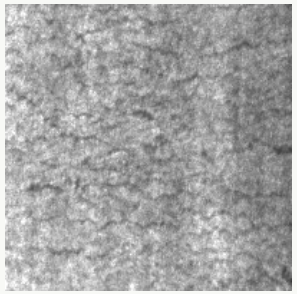
항목	내용
데이터셋	NEU Surface Defect Database (NEU-CLS)
전체 이미지	1,800 장
클래스	6 개
클래스별 이미지	300 장
이미지 크기	200×200 픽셀
이미지 형식	흑백 BMP

결함 클래스	한글명
Crazing (Cr)	균열
Inclusion (In)	개재물
Patches (Pa)	패치
Pitted Surface (PS)	표면 패임
Rolled-in Scale (RS)	압연 스케일
Scratches (Sc)	스크래치

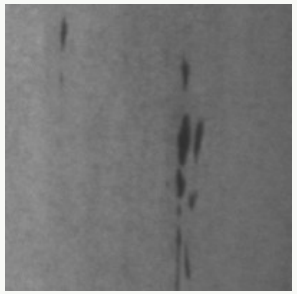
모든 이미지가 동일한 크기 · 흑백 형식으로 제공되며 , 6 개 결함 유형의 CNN 다중 분류에 사용하였다 .

EDA ① 클래스 분포 및 결함 이미지 분석

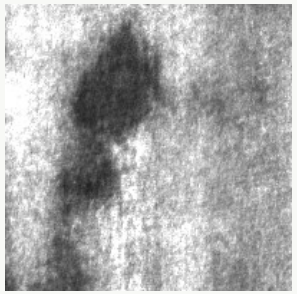
클래스 균형과 이미지의 공간적 형태 · 질감을 확인



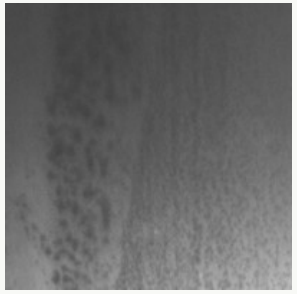
Cr 균열



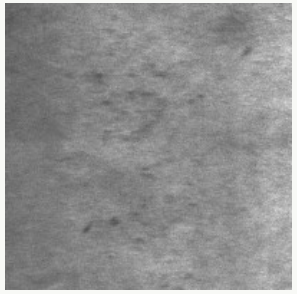
In 개재물



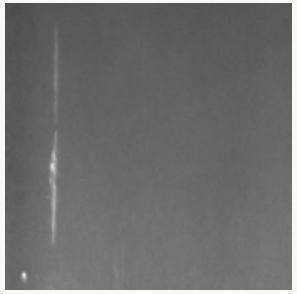
Pa 패치



PS 표면 패임



RS 압연 스케일



Sc 스크래치

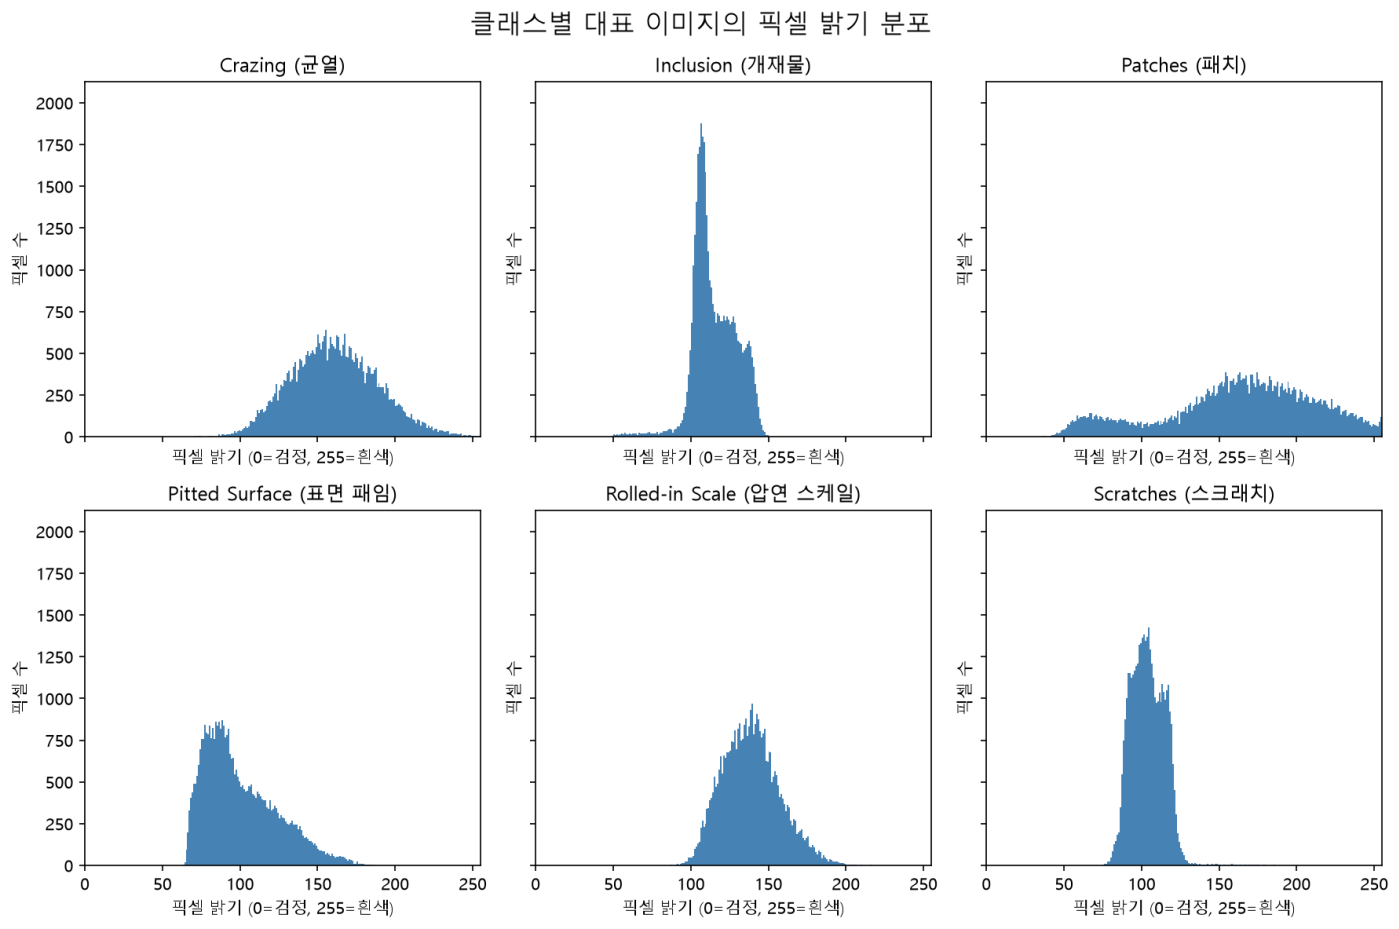
각 클래스 300 장



선형 흔적	Cr : 균열 , Sc : 방향성 있는 선
국소 영역	In : 점 · 영역 · 긴 흔적 , Pa : 패치
표면 질감	PS : 반복 패임 , RS : 불규칙 스케일

EDA 결과 형태 · 질감의 공간적 차이 ➡ **합성곱 기반 CNN 으로 특징 학습**

EDA ② 픽셀 밝기 분포 분석



전체 클래스의 통계가 아닌 클래스별 대표 이미지의 밝기 분포 분석

분석 결과

흑백 픽셀값은 0~255 범위다 .
클래스별 대표 이미지에서
일부 밝기 구간의 유사성을
관찰하였다 .

전처리 연결

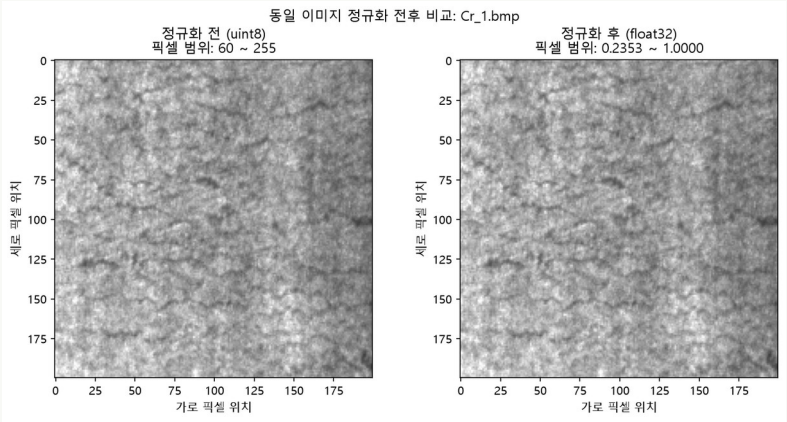
학습 시 입력 스케일을
일정하게 맞추기 위해
255 로 나누어 0~1 범위로
정규화하였다 .

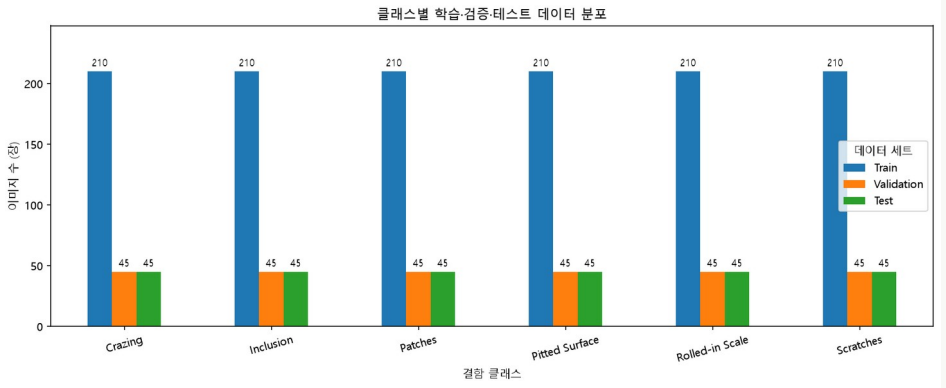
데이터 전처리 및 학습 데이터 분할

EDA 결과를 반영한 CNN 입력 구성과 계층화 데이터 분할

01	**이미지 형식 확인**	200×200 흑백 이미지 사용
02	**타입 변환**	uint8 배열을 float32 로 변환
03	**픽셀 정규화**	0~255 ÷ 255 → 0~1
04	**입력 차원 구성**	(200, 200, 1) 형태
05	**계층화 분할**	클래스 비율 유지 / random_state=42

데이터	이미지 수	비율	클래스별	역할
Train	1,260	70%	210	가중치 학습
Validation	270	15%	45	과정 확인 · 최적 모델 선택
Test	270	15%	45	모델 확정 후 최종 평가
합계	1,800	100%	300	클래스 비율 유지





Train 은 가중치 학습 , Validation 은 최적 모델 선택 , Test 는 확정된 모델의 최종 평가에 사용 .

Baseline CNN 모델 설계

Flatten 기반 기준 모델 / 총 파라미터 5,213,126 개

Input
200×200×1

Conv 32 + Pool
100×100×32

Conv 64 + Pool
50×50×64

Conv 128 + Pool
25×25×128

Flatten
80,000 차원 벡터

Dense 64
ReLU 특징 결합

Dropout 0.3
학습 중 일부 비활성화

Dense 6
Softmax 확률 출력

Conv2D

3×3 · same · ReLU
선 · 경계 · 질감 특징 추출

MaxPooling2D

2×2 로 공간 크기 축소
특징을 다음 계층에 전달

last_conv

Pooling 전 50×50×128
Grad-CAM 의 특징 맵

최종 출력

Cr · In · Pa · PS · RS · Sc
라벨 순서와 확률 대응

구조는 실제 Notebook· 저장 모델 기준 . Conv 블록 내부의 Conv2D 와 Pooling 은 하나의 단위로 묶어 표현 .

CNN 학습 설정

최적화 , 학습 반복 , 과적합 완화 및 모델 선택 기준

① 최적화 설정

항목	설정
Optimizer	Adam
Learning Rate	0.001
Loss	Sparse Categorical Crossentropy

② 학습 반복 설정

항목	설정
Batch Size	32
최대 Epoch	20

③ 과적합 완화 · 모델 선택

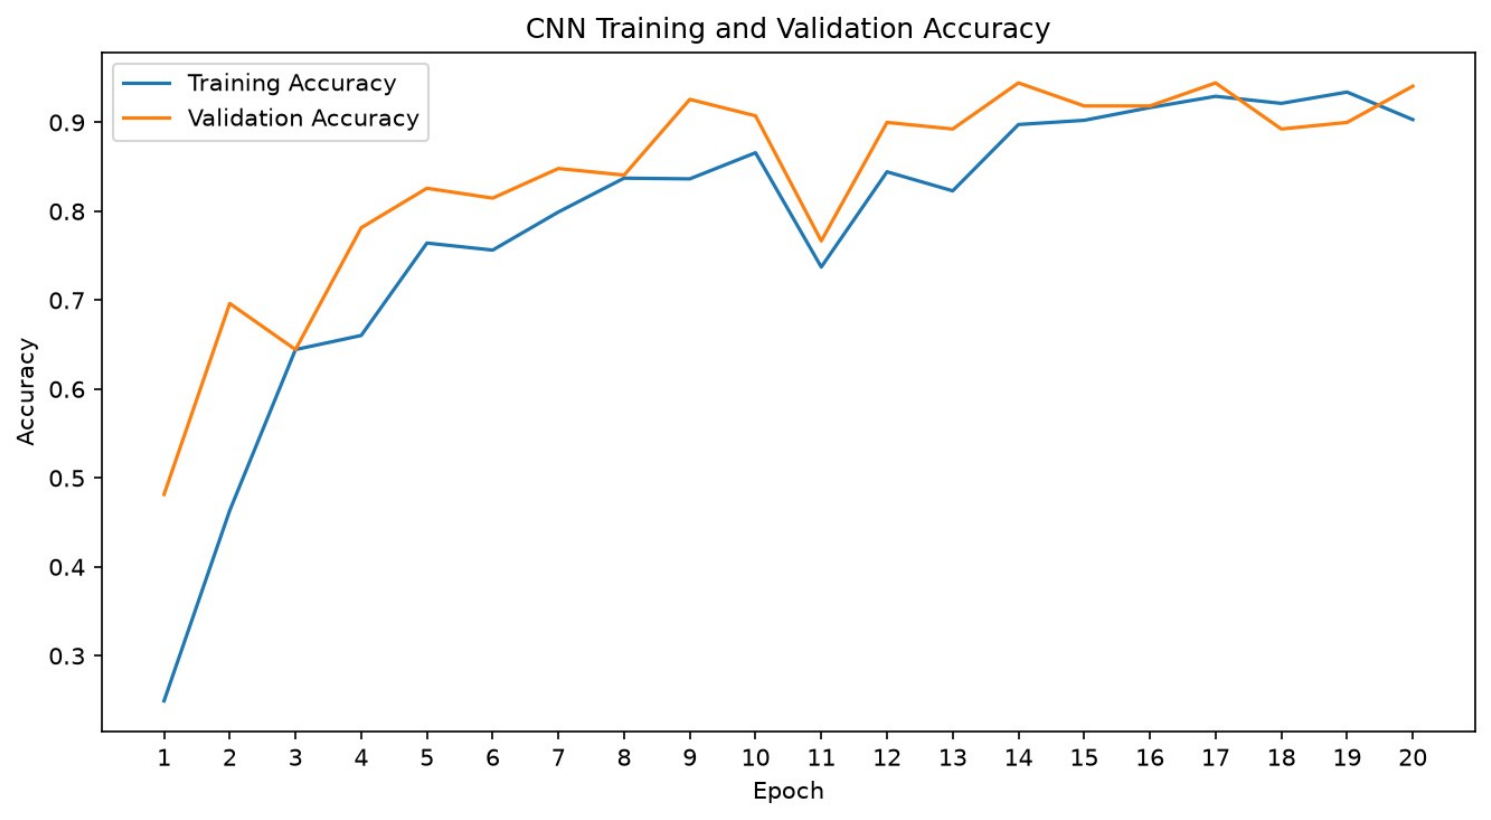
항목	설정
Dropout	0.3
EarlyStopping	val_loss 기준 patience=4
가중치 복원	restore_best_weights=True

Train 1,260 장으로 학습하고 매 Epoch 마다 Validation 270 장으로 확인하였다 .

restore_best_weights=True 를 사용하여 최저 검증 손실의 가중치를 복원하도록 설정 . 실제 학습 결과는 다음 학습 곡선에서 제시 .

Epoch 에 따른 학습 · 검증 정확도 변화

학습과 검증 곡선을 함께 비교하여 학습 추세와 성능 변동 확인



실제 학습 결과

20 Epoch 학습 완료
선택 모델 : Epoch 17
Validation Accuracy 94.44%

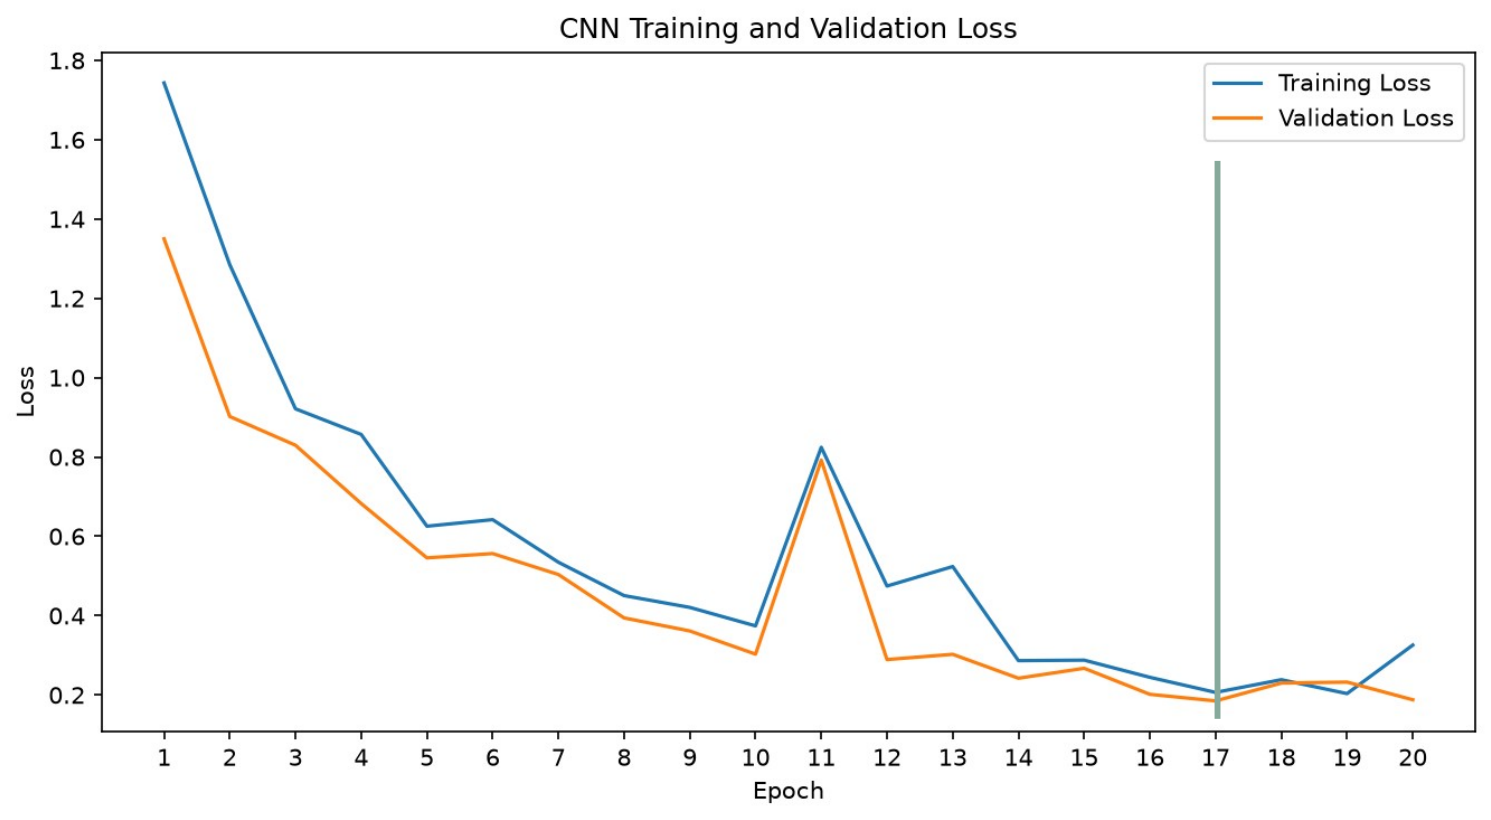
해석

초기 대비 정확도 향상
Epoch 11 에서 일시 하락 후 회복

-> 최적 모델은 검증 손실로 선택

검증 손실을 이용한 최적 학습 시점 결정

Epoch 20 까지 학습한 뒤 , 최저 Validation Loss 를 기록한 Epoch 17 의 가중치 복원



실제 학습 손실 곡선 / 최저 Validation Loss 0.1850 을 기록한 Epoch 17 의 가중치를 복원 .

선택 모델

Epoch 17
검증 손실 0.1850
검증 정확도 94.44%

손실 해석

Epoch 20 검증 손실 : 0.1878
감소 과정에서 일시적 변동 관찰

-> Epoch 17 의 최저 손실
가중치 복원

Baseline CNN 의 독립 테스트 성능

확정된 Baseline CNN / 모델 선택에 사용하지 않은 Test 270 장

평가 지표	Test 270 장 결과
Accuracy	0.9333 (93.33%)
Loss	0.1542
Macro Precision	0.9376
Macro Recall	0.9333
Macro F1-score	0.9328
Weighted F1-score	0.9328

252 / 270

정답 252 장 / 오분류 18 장

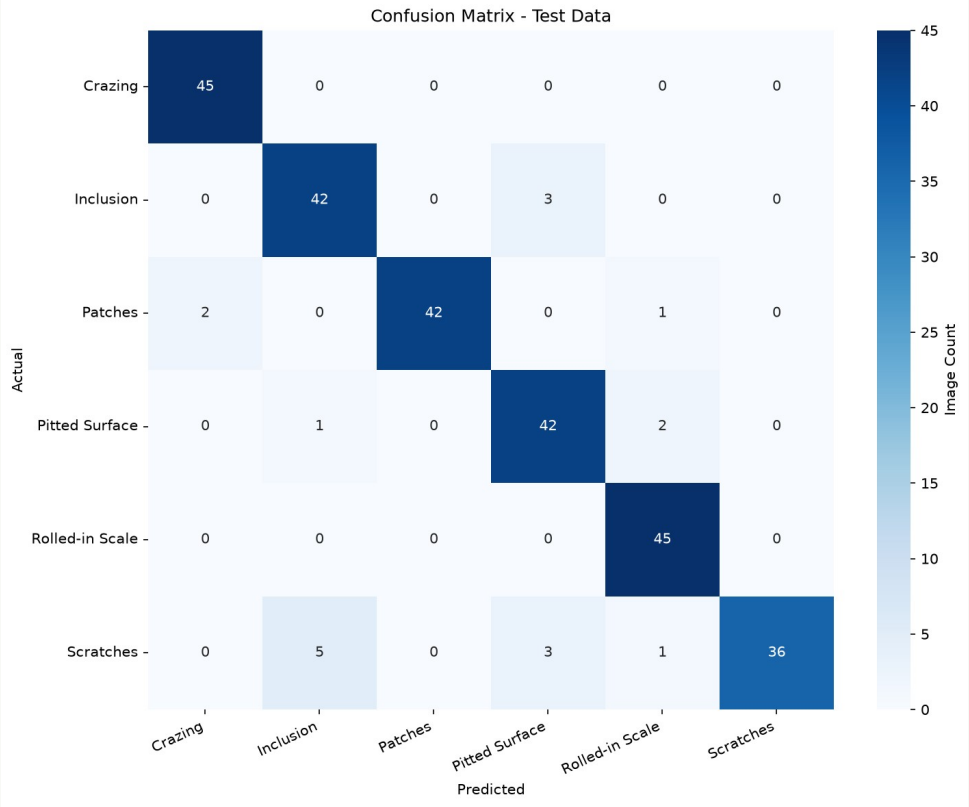
6 개 클래스 × 각 45 장

검증 정확도 94.44% 대비
테스트 정확도는 1.11%p 낮았다 .

후속 분석 혼동행렬과 클래스별 지표로 오분류가 집중된 유형을 확인

클래스 간 오분류 관계 분석

Test 270 장 혼동행렬 / 행은 실제 클래스 , 열은 예측 클래스



45 / 45 장 정답

Crazing · Rolled-in Scale

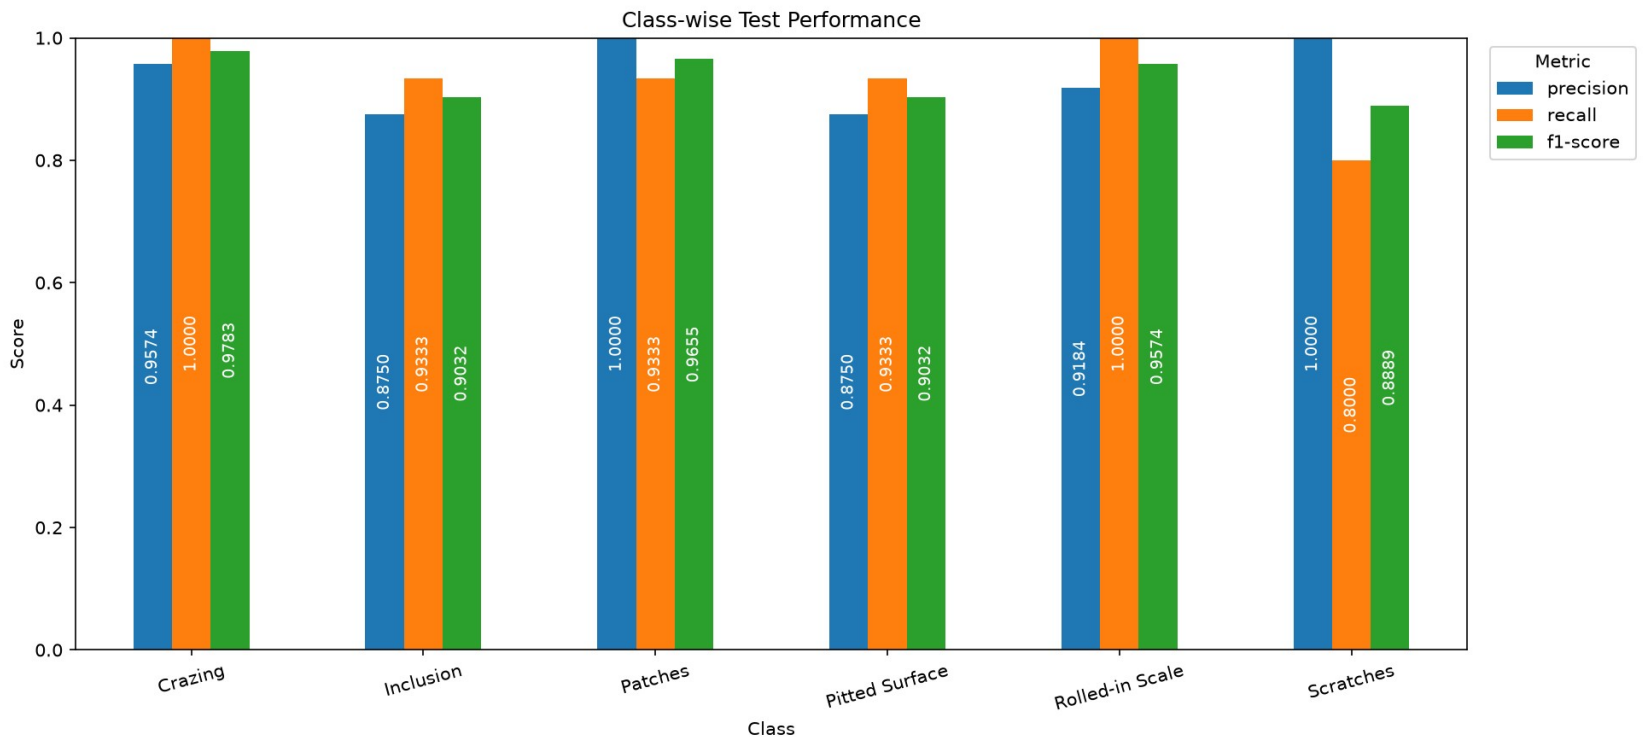
Scratches 오류 9 장

예측한 클래스	오류 건수
Inclusion	5 장
Pitted Surface	3 장
Rolled-in Scale	1 장

Scratches 오류 이미지를 세부적으로 검토하고 Grad-CAM 으로 예측 기여 영역을 추가 분석하였다 .

Baseline CNN 의 클래스별 성능 분석

독립 테스트 270 장 / 클래스별 Precision·Recall·F1-score 비교



주요 지표	Test 결과
Accuracy	93.33%
Macro F1	0.9328
Sc Recall	80.00%
Sc 오분류	9 건

결과 해석

전체 정확도는 93.33% 였으나
Scratches Recall 은 80.00% 였다 .
클래스별 지표로 오류가 집중된
유형과 혼동 관계를 분석하였다 .

Scratches 는 실제 45 장 중 36 장 정답 , 9 장 오분류로 전체 오류 18 건의 절반을 차지하였다 .

스크래치를 개재물로 예측한 사례 분석

실제 라벨 Scratches / 예측 라벨 Inclusion 인 테스트 이미지 5 장



이미지에서 관찰한 특징

선형 긁힘과 함께 주변의 불규칙한 질감 · 어두운 영역이 보임 .
Inclusion 예측 확률은 0.4938~0.8566.

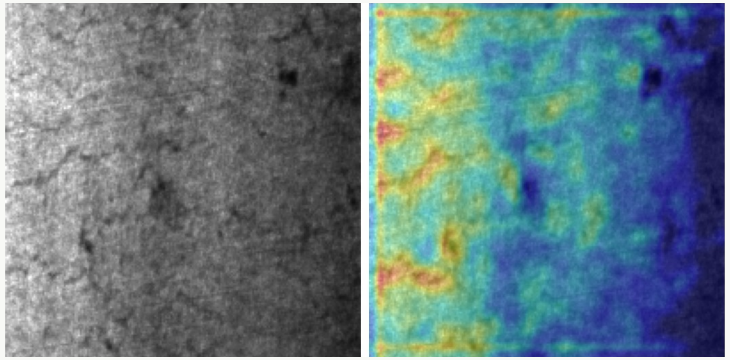
후속 분석

선형 긁힘과 주변 질감이 함께 나타나는 사례를
선별하여 Grad-CAM 의 공간적 기여도를 확인하였다 .

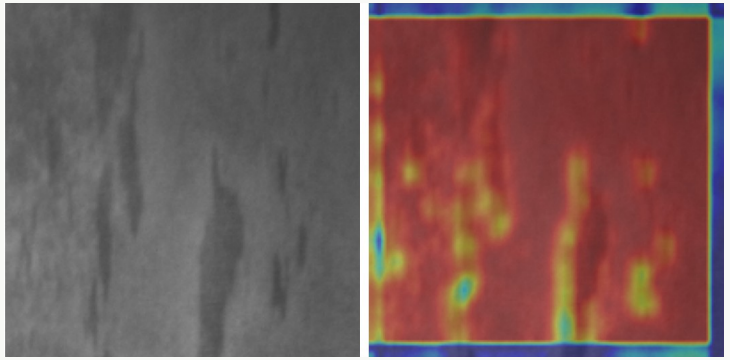
Grad-CAM ① 정답 예측의 관심 영역 분석

마지막 합성곱 계층 last_conv 와 예측 클래스의 기울기를 이용하여 정답 예측 6 종의 기여 영역 비교

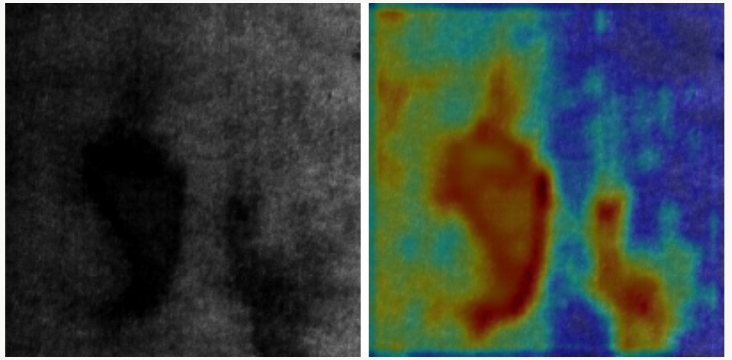
Cr 균열 / 확률 98.28%



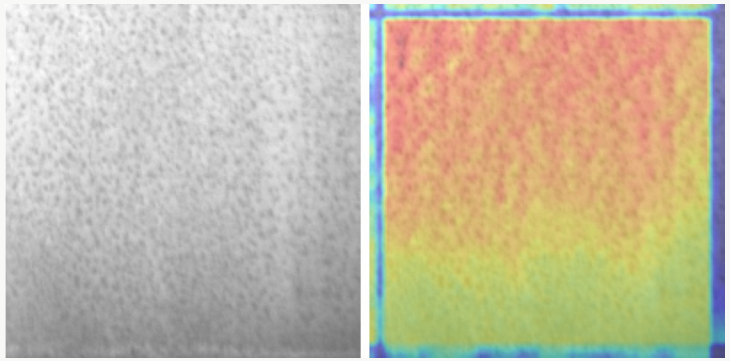
In 개재물 / 확률 93.53%



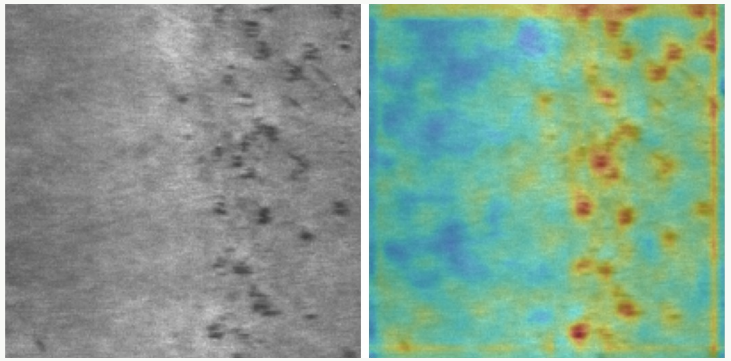
Pa 패치 / 확률 100.00%



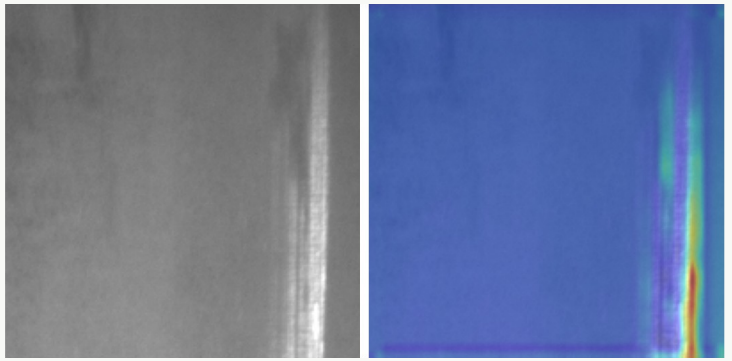
PS 표면 패임 / 확률 99.19%



RS 압연 스케일 / 확률 99.87%



Sc 스크래치 / 확률 92.00%



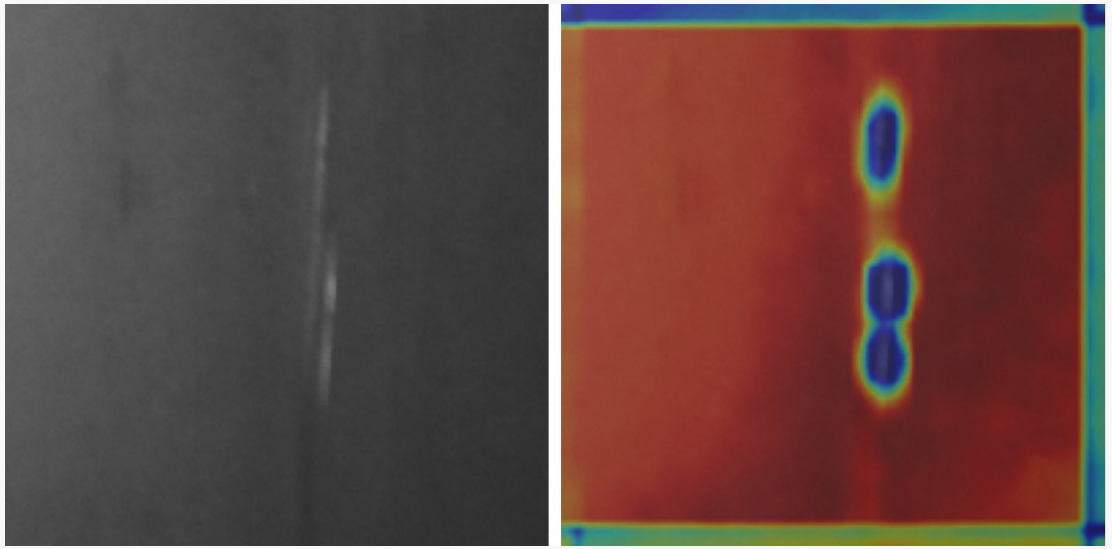
각 쌍의 왼쪽은 원본 , 오른쪽은 Grad-CAM. Scratches 정답은 밝은 세로선 주변에 높은 기여도를 보였으며 , 실제 결함 위치 검출 결과는 아님 .

Grad-CAM ② 오분류 이미지의 관심 영역 분석

테스트 오분류 18 건 중 Scratches 9 건 / Scratches → Inclusion 5 건의 대표 사례 확대

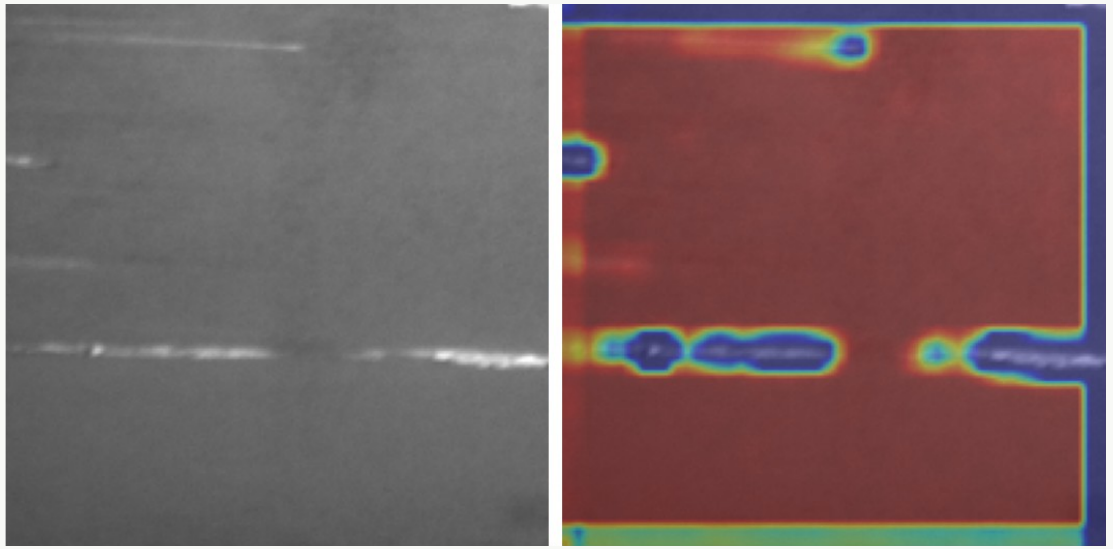
실제 Scratches 를 Inclusion 으로 예측한 두 이미지의 원본과 Grad-CAM 을 나란히 비교하였다 .

Test index 24 / Inclusion 71.84%



밝은 선 일부는 기여도가 낮고
주변 배경에 넓은 관심 영역이 나타났다 .

Test index 33 / Inclusion 85.66%



가로 선 주변과 넓은 표면 영역의
기여도 분포 차이를 관찰하였다 .

이미지별 상대 기여도를 오분류 원인의 탐색적 참고 자료로 활용하였다 . 시각화만으로 오분류의 인과적 원인을 확정하지 않음 .

추가 실험 — CNN 모델 경량화 비교

Flatten 을 GlobalAveragePooling2D 로 교체하고 , 동일 Validation 270 장으로 비교

공통 특징 추출부

Input (200×200×1) → Conv2D / MaxPooling × 3

Baseline CNN

Flatten

80,000 개 특징

GAP CNN

GlobalAveragePooling2D

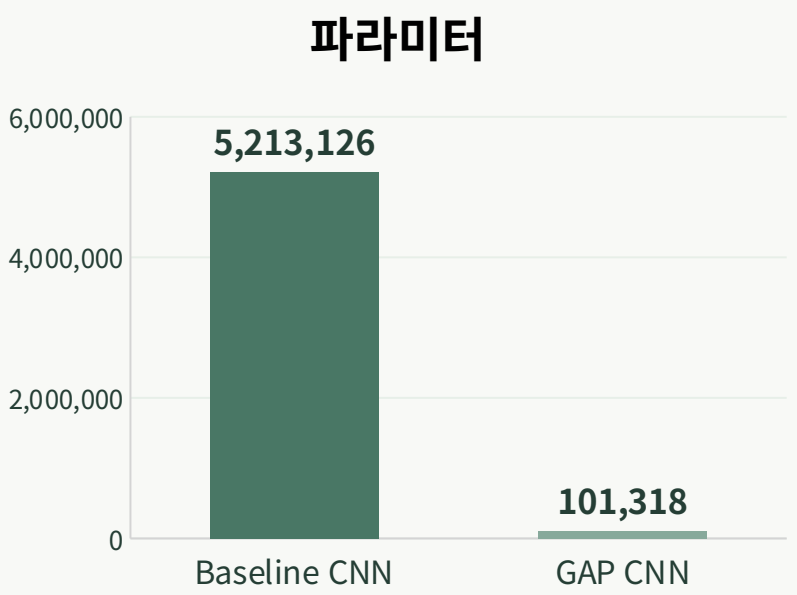
128 개 특징

공통 분류기

Dense(64) → Dropout(0.3) → Softmax(6)

공통 계층과 학습 설정은 유지 . 모델 가중치 수 기준이며 Optimizer 상태는 제외 .

모델 파라미터 수



파라미터 약 98.06% 감소

CNN 모델 검증 성능 비교

동일한 Validation 데이터 270 장 기준 / 기존 Test 는 이번 모델 비교와 추가 학습에 사용하지 않음

지표	Baseline CNN	GAP CNN	변화 (GAP − Baseline)
Validation Accuracy	94.44%	90.37%	−4.07%p
Validation Loss	0.185013	0.264013	+0.079000
Validation Macro F1	0.944891	0.904352	−0.040540
파라미터 수	5,213,126	101,318	−98.06%
학습 시간 (참고)	664.35 초	565.98 초	약 − 14.8%
최적 Epoch	17	20	모두 20 Epoch 실행
오분류 건수	15 장	26 장	+11 장

경량화와 검증 성능 사이의 절충

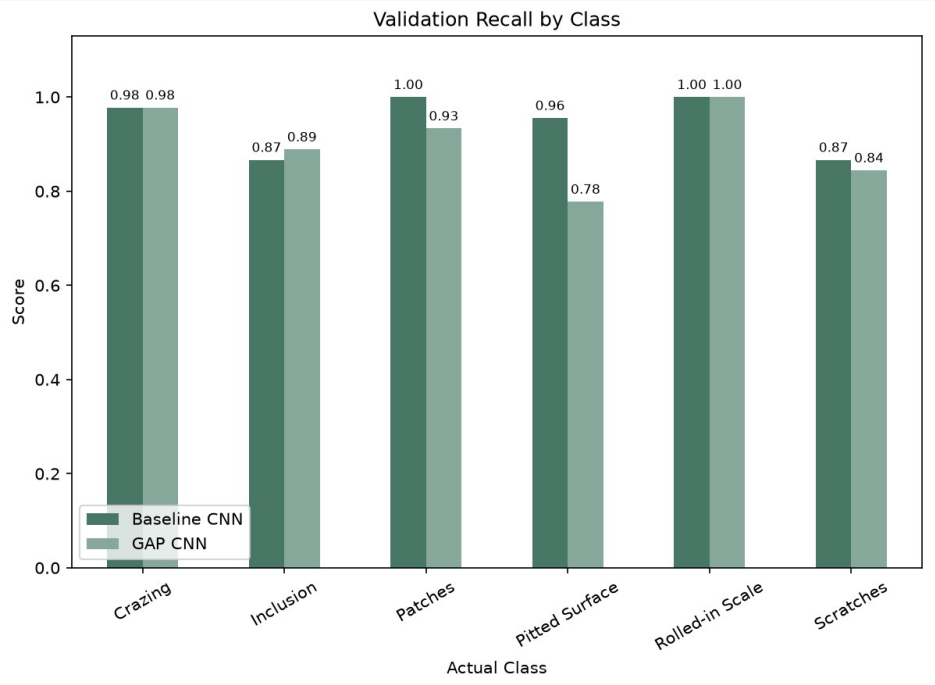
파라미터는 98.06% 줄었으나 정확도는 4.07%p 하락

학습 시간은 서로 다른 실행 시점의 측정값이므로 참고만 함 .

클래스별 분류 성능 비교

동일 Validation 에서 결함 유형별 Recall 변화 / 각 클래스 45 장

클래스	Baseline	GAP	변화 (%p)
Crazing	97.78%	97.78%	0.00
Inclusion	86.67%	88.89%	+2.22
Patches	100.00%	93.33%	-6.67
Pitted Surface	95.56%	77.78%	-17.78
Rolled-in Scale	100.00%	100.00%	0.00
Scratches	86.67%	84.44%	-2.22



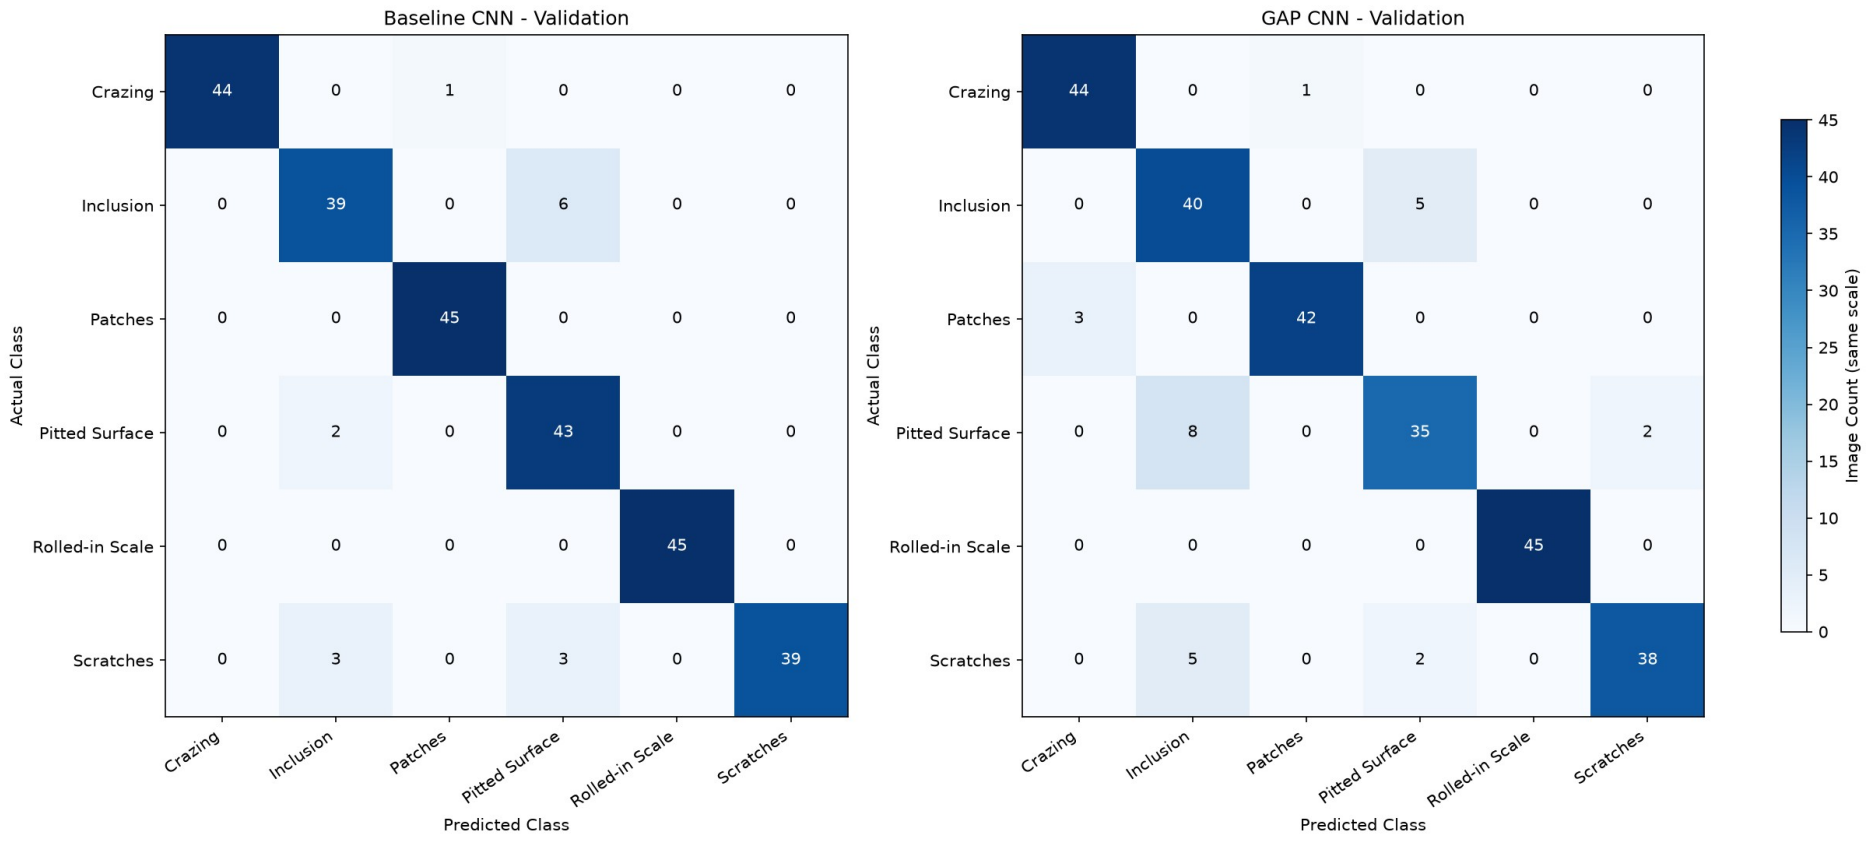
Pitted Surface: 가장 큰 하락

43 / 45 장 → 35 / 45 장 정답
Recall 95.56% → 77.78% (−17.78%p)

Inclusion: Recall 과 F1 의 차이

Recall 86.67% → 88.89% 로 상승했으나 ,
F1 은 0.8764 → 0.8163 으로 하락

동일 Validation 혼동행렬 비교



동일한 Validation 270 장 비교에서 GAP CNN 은 일부 결함 유형의 오분류가 증가하였다 .
특히 Pitted Surface 를 Inclusion 으로 잘못 분류한 사례는 **2 건에서 8 건으로** , Scratches 를 Inclusion 으로 잘못 분류한 사례는 **3 건에서 5 건으로** 증가하였다 .

추가 경량화 실험 결과 — Baseline CNN 유지

동일 Validation 비교에 따른 최종 모델 판단

Baseline CNN 유지

GAP 은 파라미터를 약 98.06% 줄였지만 검증 정확도가 4.07%p 하락하였다 .
분류 성능을 우선하여 기존 Baseline CNN 을 유지하고 웹앱에 적용하였다 .

GAP CNN 의 효과

모델 파라미터 감소
추론 속도 향상 여부는 검증하지 않음

Baseline CNN 을 유지한 근거

높은 Validation Accuracy 와 Macro F1
GAP 에서 Pitted Surface Recall 이 크게 하락
Streamlit 의 기존 분류 모델로 사용

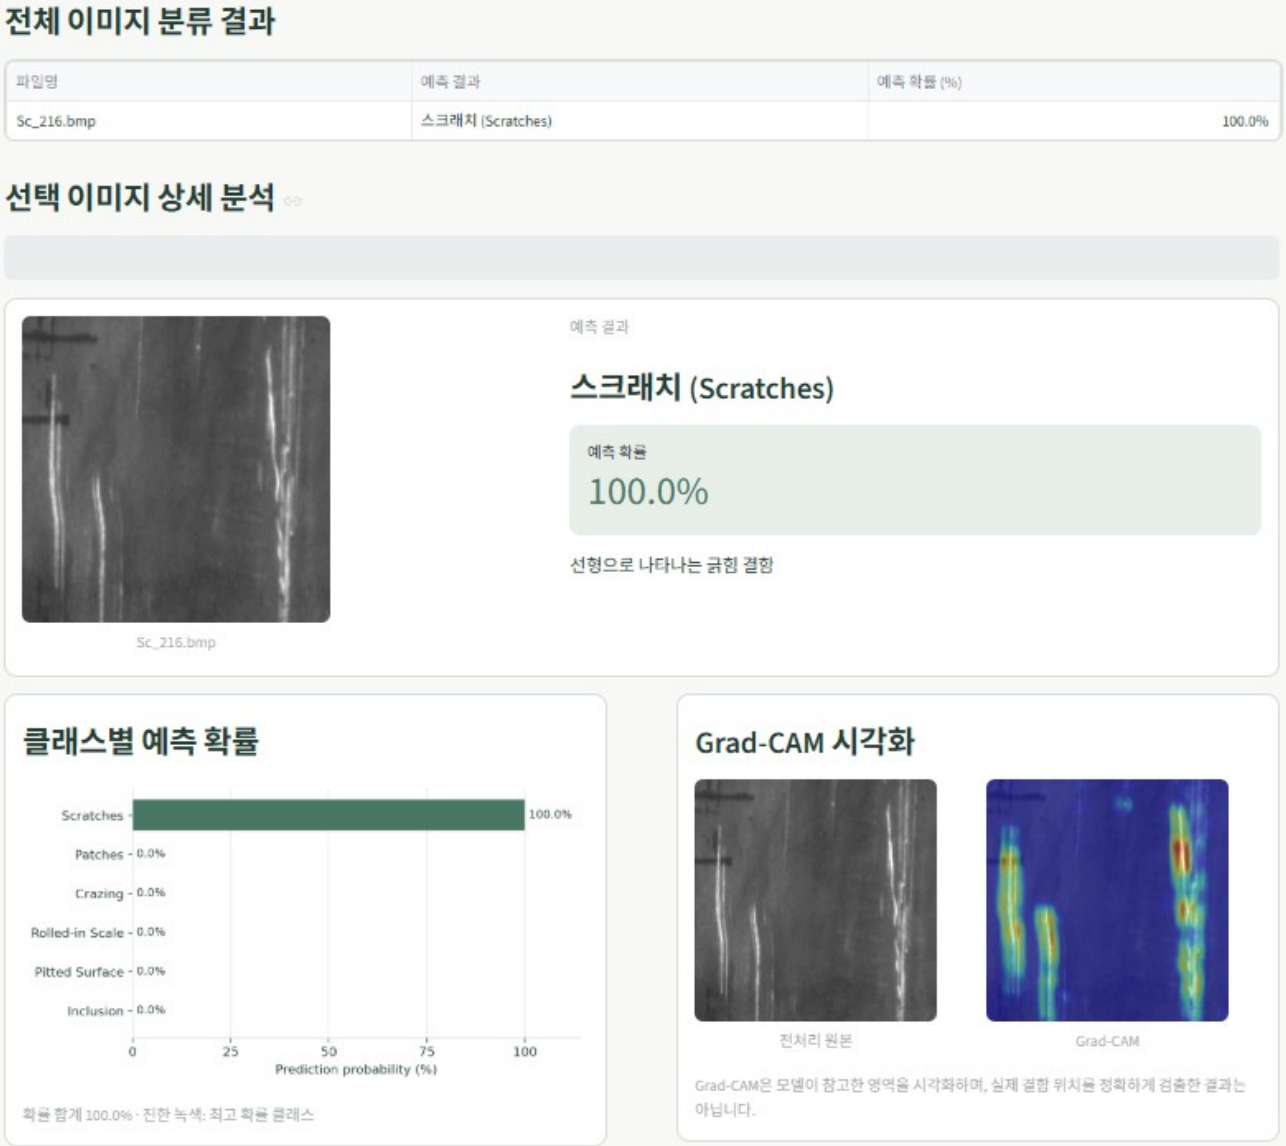
Streamlit 웹앱 — 실제 실행 결과

저장된 Baseline CNN 을 Streamlit 에 연동하여 결함 유형 , 클래스별 예측 확률 , Grad-CAM 결과를 제공하였다 .

실행 사례

Sc_216.bmp
스크래치 (Scratches) 로 분류
예측 확률 100.0%

100.0% 는 해당 이미지의 예측 확률이다 .
모델의 독립 Test 정확도는 93.33% 이다 .



Streamlit Community Cloud 배포

GitHub 소스에서 모델 추론과 분석 결과 제공까지의 배포 흐름

GitHub 저장소 ➡ **Streamlit Community Cloud** ➡ **TensorFlow 모델 로드** ➡ **분석 결과 제공**

소스와 모델 전달 | 웹앱 실행 | 이미지 추론 준비 | 분류 · 확률 · Grad-CAM 표시

실행 환경 및 구현 정보	실제 구성
배포 플랫폼	Streamlit Community Cloud
Python	3.11
모델 파일	models/cnn_model.keras
사용자 기능	이미지 업로드 , 결함 분류 , 예측 확률 , Grad-CAM

TensorFlow 패키지 설치 오류가 발생하였으나 , 배포 Python 버전을 3.11 로 변경하여 정상 배포하였다 .

https://metal-surface-defect-nanmcuhpbmfgmsbcajwknc.streamlit.app/

모델 성능 개선 방향

클래스별 분류 성능 차이와 GAP 경량화 실험 결과를 바탕으로 개선 방향 검토

항목	현재 확인된 한계	향후 개선 · 검토 방향
Scratches 의 낮은 Recall	Test Recall 80.00% 45 장 중 9 장 오분류	다양한 스크래치 형태 · 표면 질감의 데이터 추가 확보 및 증강 검토
GAP 경량화 시 분류 성능 감소	파라미터 98.06% 감소 Val Accuracy 4.07%p 하락 PS Recall 95.56% → 77.78%	특징 추출 계층 보완 , BatchNormalization 등을 통한 성능 · 경량화 균형 검토
클래스 간 시각적 유사성	Scratches 와 Inclusion 등 일부 결함 유형의 혼동 확인	혼동 클래스의 이미지 특징을 추가 분석하고 필요한 데이터 다양성 확보

위 개선안은 후속 검토 사항이며 , 실제 성능 개선 효과는 별도 실험으로 검증해야 한다 .

현장 적용을 위한 추가 검증

프로토타입의 데이터 범위와 실제 제조 환경 적용 전 검증 필요사항

항목	현재 확인된 한계	향후 개선 · 검토 방향
정상 제품 클래스 부재	정상 · 미학습 이미지도 6 개 결함 중 하나로 분류되며 , 높은 Softmax 확률이 표시될 수 있음	정상 이미지 확보 및 정상 / 불량 구분 기능과 미학습 이미지에 대한 불확실성 처리 방법을 검토
실제 제조 환경 검증 부족	NEU-CLS 기준으로 평가 실제 생산 현장 이미지 성능 미검증	실제 제조 환경에서 확보한 별도 이미지로 일반화 성능 평가
촬영 조건 변화 검증 부족	조명 · 각도 · 카메라 · 노이즈 등 촬영 조건별 성능 미검증	촬영 조건을 다양화한 데이터를 확보하고 모델의 강건성 확인

현재 시스템은 NEU-CLS 기반 판독 보조 프로토타입이며 , 실제 현장 적용에는 추가 검증이 필요하다 .

프로젝트 결론 및 활용 가능성

01 구현 결과

NEU-CLS 금속 표면 전체 1,800 장을 분할하고 , Train 1,260 장으로 CNN 을 학습하였다 .

93.33%

독립 Test 270 장 정확도
Macro F1-score 0.9328

02 분석 및 모델 선정

Scratches Recall 80.00% 를 확인하고 , 오분류 ·Grad-CAM 으로 판단 영역을 분석하였다 .
GAP 은 파라미터 98.06% 감소와 Validation Accuracy 4.07%p 하락을 보였다 .

분류 성능을 우선하여 Baseline CNN 유지

03 활용 가능성

최종 모델을 Streamlit 에 연동하여 이미지 업로드 , 결함 유형 , 예측 확률 및 Grad-CAM 결과를 확인하도록 구현하였다 . 금속 표면 결함 유형을 확인하는 판독 보조 프로토타입으로 활용할 수 있다 .

프로젝트 회고

프로젝트를 진행하며 느낀 점

데이터 분석

- EDA 를 진행하면서 클래스별 이미지 수가 균형적이어도 결함의 형태나 질감이 비슷하면 분류가 어려울 수 있다는 점을 알게 되었다 . 모델을 만들기 전에 데이터의 특성을 충분히 살펴보는 과정이 중요하다고 느꼈다 .

모델 평가

- 전체 테스트 정확도는 93.33% 였지만 스크래치의 재현율은 80% 에 그쳤다 . 앞으로는 전체 정확도만 확인하는 것이 아니라 클래스별 성능과 혼동행렬도 함께 분석해야겠다고 생각했다 .

모델 비교

- GAP 를 적용하면 성능을 유지하면서 모델을 가볍게 만들 수 있을지 궁금해 추가 실험을 진행했다 . 파라미터 수는 약 98% 감소했지만 검증 정확도가 하락하면서 모델을 선택할 때는 성능과 효율을 함께 고려해야 한다는 것을 배웠다 .

웹앱 구현

- 학습한 모델을 웹앱에 연결하는 과정에서 라이브러리 호환성과 화면 표시 문제가 발생했다 . 이를 해결하면서 실제로 사용할 수 있는 결과물을 만들기 위해서는 모델 성능뿐 아니라 배포 환경과 사용자 화면도 중요하다고 느꼈다 .